



以图为中心的新型大数据技术栈研究^{*}

沈志宏¹ 赵子豪^{1,2} 王海波¹

¹(中国科学院计算机网络信息中心 北京 100190)

²(中国科学院大学 北京 100049)

摘要:【目的】传统的以SQL为中心的技术栈无法有效地应对大数据场景带来的多元异构数据管理、大规模关系网络管理和复杂网络分析等挑战,本文针对新型大数据技术栈展开研究。【方法】通过分析图数据模型的优势,结合图技术的发展和应用现状,提出以图为中心的新型大数据技术栈,并介绍了智能融合数据管理系统PandaDB。【结果】该技术栈在生物数据网络、科技知识图谱等实际应用中得到较好的验证,PandaDB具备良好的结构化、非结构化数据融合管理能力。【局限】该技术栈的大面积推广还存在支撑工具不足、应用生态不够成熟等困难。【结论】以图为中心的新型大数据技术栈会在更多的大数据应用场景中发挥更大的价值。

关键词: 图模型 图数据库 数据仓库 技术栈

分类号: TP393

DOI: 10.11925/infotech.2096-3467.2020.0452

引用本文: 沈志宏, 赵子豪, 王海波. 以图为中心的新型大数据技术栈研究[J]. 数据分析与知识发现, 2020, 4(7): 50-65.(Shen Zhihong, Zhao Zihao, Wang Haibo. Big Data Technology Stack Shifting: From SQL Centric to Graph Centric[J]. Data Analysis and Knowledge Discovery, 2020, 4(7): 50-65.)

1 以SQL为中心的技术栈

1969年,Codd提出关系模型(Relational Model),旨在以元组(Tuple)和关系(Relation)来表达和组织数据^[1]。遵循关系模型的数据库即关系数据库,或称为关系数据库管理系统(RDBMS)。1974年,IBM开始第一个关系数据库System R的研发;1979年,Oracle公司推出第一个商业数据库Oracle。随后,关系数据库得到迅猛发展,并逐渐成为主导的数据库类型,包括DB2、SAP Sybase、Informix等。

RDBMS广泛应用于联机事务处理(OnLine Transaction Processing, OLTP)和联机分析处理(OnLine Analytical Processing, OLAP)的场景,OLAP系统一般以数据仓库(Data Warehouse, DW)作为基础,即从数据仓库中抽取详细数据的一个子集并经过必要的聚集存储到OLAP存储器中供前端分析工具读取^[2]。作为商业智能的关键部分,数据仓库主要用以数据的统计分析,可进一步区分为关系OLAP(Relational OLAP, ROLAP)、多维OLAP(Multidimensional OLAP, MOLAP)和混合型OLAP

通讯作者: 沈志宏, ORCID: 0000-0002-0113-0478, E-mail: bluejoe@cnic.cn。

^{*}本文系国家重点研发计划云计算和大数据专项“科学大数据管理系统”(项目编号: 2016YFB1000605)、中国科学院计算机网络信息中心与国家自然科学基金委员会合作项目“国家自然科学基金大数据知识管理服务系统”(项目编号: GC-FG4161781)和中国烟草总公司科技重大专项项目“烟草科研数据融合与关联挖掘关键技术研究”(项目编号: 110201801019(SJ-01))的研究成果之一。

(Hybrid OLAP, HOLAP) 三种类型。其中, ROLAP 直接采用 RDBMS 存储; MOLAP 则将 OLAP 分析所用到的多维数据存储为多维数组的形式, 形成“数据立方体”的结构, 底层仍以 RDBMS 为主, 综合列式存储、内存数据管理等系统搭建而成。

结构化查询语言 (SQL) 的提出和推广, 促进了 RDBMS 以及数据仓库技术的广泛应用。几乎所有的 RDBMS 都提供了 SQL 语言的支持, 另外, 数据仓库经常借助 ETL (Extract, Transform, Load) 工具, 如 DataPipeline、Kettle^[3]、Talend^[4]、Informatica^[5]、DataX^[6]、Oracle GoldenGate^[7] 等, 来实现多源数据的集成和转换, 这个过程往往会借助于 SQL 语言完成。

SQL 语言在云计算和大数据时代仍占有重要地位, 这方面的应用具体表现为三种形态: SQL on Hadoop、SQL over NoSQL 以及 Analytical SQL。

(1) SQL on Hadoop

基于 Hadoop/Spark 构建的 SQL 引擎, 如: Hadoop 生态中的重要 Hive 数据仓库系统^[8], 对内屏蔽了 HDFS、HBase 等存储的差异性, 对外仅暴露了 HiveQL 语言作为查询语言; Spark 中相应的模块为 Spark SQL, 它基于 DataFrame 和 DataSet 两个编程抽象, 提供了分布式 SQL 查询引擎; 第三方的 SQL 引擎如 Impala^[9], 提供了 SQL 语义, 能查询存储在 Hadoop 的 HDFS 和 HBase 中的 PB 级大数据。

(2) SQL over NoSQL

针对 NoSQL 数据库对外暴露 SQL 查询接口,

如: Apache Phoenix^[10] 针对 HBase 封装了 SQL 化的操作接口; solr-sql^[11] 实现了针对文档搜索引擎 Solr 的 SQL 接口; 著名的 SQL 引擎 Apache Calcite^[12] 则将 SQL 引入到流式数据的实时查询和分析; 2006 年, 有学者提出 CQL (Continuous Query Language) 的概念^[13], 华为于 2015 年推出开源其流处理平台 SQL 引擎 StreamCQL。作为华为 FusionInsight^[14] 大数据平台的重要组件, StreamCQL 提供了在分布式流处理平台上的类 SQL 查询能力。

(3) Analytical SQL

SQL 语言不仅用于数据库的查询分析和 ETL, 还被扩展到更多数据分析的场合。多维分析的例子如 Apache Kylin^[15], 基于 HBase 存储, 通过采用预计算和分层立方体的方法实现了多维数据的统计和快速查询, 其中统计的语言采用 SQL, 如图 1 所示。2018 年, 谷歌在 BigQuery^[16] 服务上推出 BigQueryML^[17], 作为 BigQuery 功能的一部分, BigQueryML 可以让数据科学家和分析师在大型的结构化或半结构化的数据集上构建和部署机器学习模型。另外一个例子是 SQLFlow^[18], SQLFlow 的目标是将 SQL 引擎和 AI 引擎连接起来, 仅需使用几行 SQL 代码即能描述整个应用或者产品背后的数据流和 AI 构造。其中所涉及的 SQL 引擎包括 MySQL、Oracle、Hive、SparkSQL、Flink 等, AI 引擎包括 TensorFlow、PyTorch 等深度学习系统, 也包括 XGBoost、LibLinear、LibSVM 等传统机器学习系统。

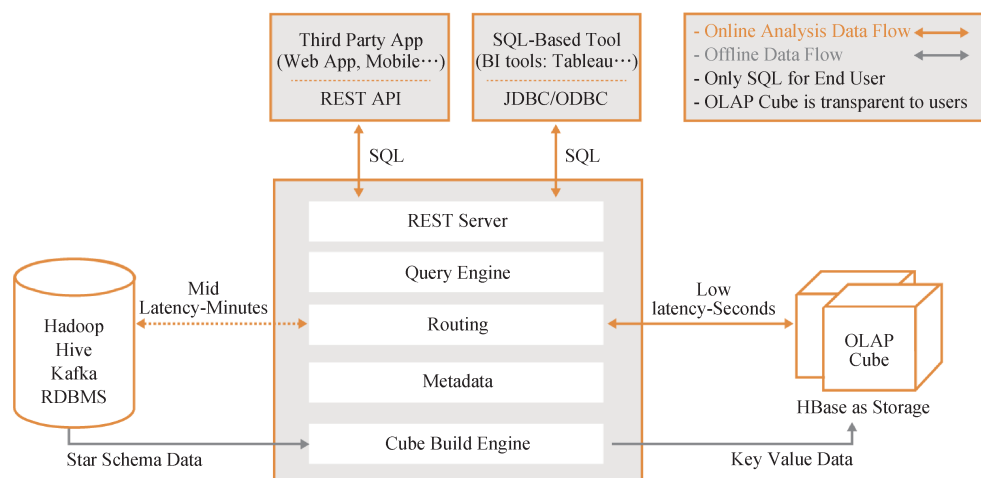


图 1 Apache Kylin 提供 SQL 的多维统计接口^[15]

Fig.1 Multidimensional Analysis Interface of SQL in Apache Kylin

可以看出,在过去 50 年的数据管理与分析技术的发展历史中,SQL 及关系模型扮演着极其重要的角色。图 2 从模型、语言、关键技术、工具、场景、应

用等层次展示出以 SQL 为中心的技术栈,信息系统一旦采用以 SQL 为中心的技术栈,就意味着具有更大的技术开放性、稳定性和可扩展性。

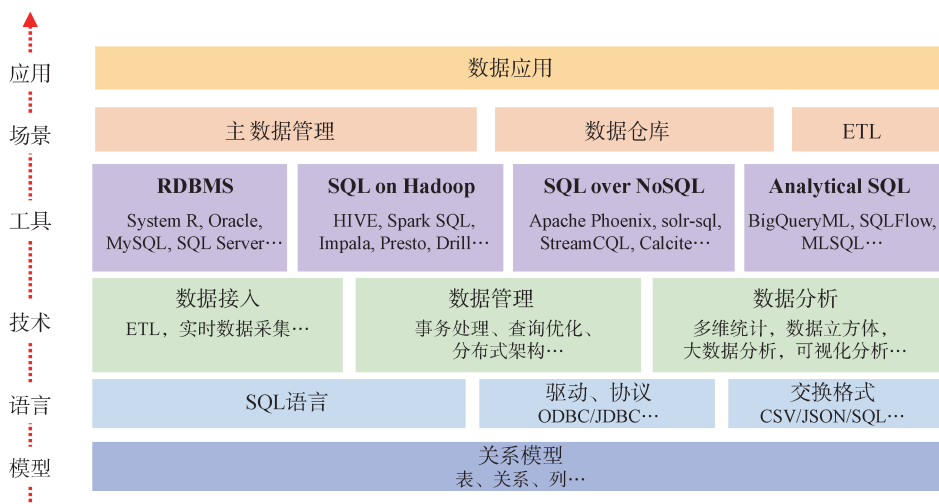


图 2 以 SQL 为中心的技术栈

Fig.2 SQL Centric Technology Stack

2 新型大数据技术栈的需求

大数据技术和应用的迅猛发展,给占据主导地位的 SQL 技术栈带来了新的挑战,这些挑战主要包括:多元异构数据的融合管理、大规模关系网络的管理与复杂的网络分析需求。

2.1 多元异构数据的融合管理需求

大数据具备显著的 4V 特征,即:体量大(Volume)、多元性(Variety)、速度快(Velocity)、价值大(Value)^[19]。从多元性来看,除了结构化数据之外,大数据更多地体现为海量的文本、图像、音频、视频等类型的非结构化数据。有研究指出,在所有的数据中,非结构化数据占据到高达 85% 的比重^[20]。

传统的 RDBMS 不能高效地管理多元异构数据,这些冲突主要体现在以下方面。

(1) RDBMS“先建模(Schema First)”的模式带来建模的不灵活性。

(2) 传统架构很难支持水平扩展。

(3) SQL 引擎所秉承的 ACID (Atomicity, Consistency, Isolation, Durability) 原则,成为实现轻

型数据管理的沉重包袱。

基于此,NoSQL 的概念被提出^[21]。NoSQL 数据库自发明之日起,就具备利于大数据存储的特性^[22-23]:无模式(schema-less)、可水平扩展的架构、更为宽松的 BASE (Basically Available, Soft-state, Eventual Consistency) 原则。通常认为 NoSQL 数据库包括 4 种类型,即 KV 数据库、列式数据库、文档数据库和图数据库。

SQL/NoSQL/NewSQL 技术虽然实现了对多元数据的管理,但数据的孤岛化问题仍然存在,各类数据管理系统之间还是存在明显的边界。基于此,业界推出了诸如 Multi-model Database^[24]、Polystore 等混合式数据管理系统架构,以及 Lambda^[25]、Kappa^[26] 等混搭式大数据架构,然而,这种混搭式的技术架构又大大增加了开发和运维的成本及难度。如图 3 所示,作为 Polystore 的一个典型实现系统,BigDAWG^[27] 将数据划分为关系型数据区、数组区以及文本区,底层分别基于 PostgreSQL、SciDB、Accumulo 作为存储,这种架构要求开发人员掌握不同系统之间的 Cast 语法,并要求运维人员熟练掌握三类数据库系统,难度较大。

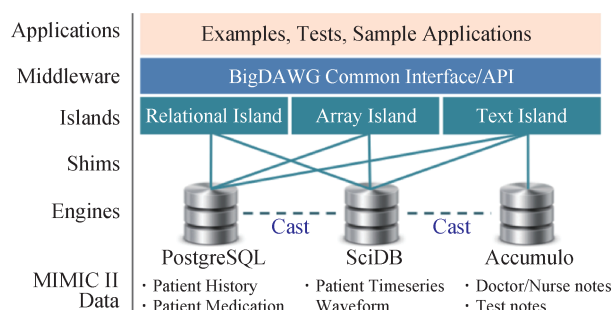
图3 BigDAWG系统架构^[27]

Fig.3 Architecture of BigDAWG

2.2 大规模关系网络的管理需求

“关系”以及实体关系构成的“网络(Network)”广泛存在现实世界和信息世界,常见的网络包括社交网络、通信网络、Internet、道路网络、生物网络、学术资源网络等。以社交网络为例,随着移动互联网时代用户生成内容(UGC)的不断发展,用户可以随时随地在网络上分享内容,由此产生了海量的用户数据。社交网络中需要表达的要害除了人物、内容、事件之外,更多的是它们之间的复杂关系,如人物与人物之间的“关注”关系,人物与内容之间的“点赞”

“评论”“转发”等各种关系。以Facebook和Twitter为例,庞大的社交网络中存在数以亿计的用户及用户间好友(关注)关系的数据^[28-29]。

2006年以来,知识图谱应用的迅猛发展,更刺激了对大规模关系网络的管理需求。知识图谱本质上是一种叫作语义网络(Semantic Network)的知识库,即具有有向图结构的一个知识库^[30]。以学术领域为例,Springer Nature于2017年推出SciGraph关联开放数据平台^[31],发布了科研资助机构、科研项目及拨款、会议、科研单位和出版物的信息,该平台计划累计15~20亿的三元组。另外,微软和清华大学推出了OAG^[32],旨在整合全球学术知识图谱、公开共享学术图谱数据,并提供相关学术搜索和数据挖掘服务。截至2019年1月,OAG 2.0版本包含约7亿实体数据和约20亿实体之间的链接关系。

表1列举出一些由SNAP^[33]和BigDND^[34]收录的关系网络数据集,可以看出,在大规模的网络或知识图谱中,“关系(边)”不仅成为很重要的要素,而且还会比“实体(顶点)”占据更大的比例。

表1 关系网络数据集的数据规模示例

Table 1 Size of Network Datasets

名称	顶点规模	边规模	描述
Wiki-Talk	2 394 385 篇文章	5 021 410 条交流关系	Wikipedia Talk 网络
Amazon0601	403 394 类商品	3 387 388 条“合买”(Co-purchasing)	Amazon 产品合买记录
Flickr	11 195 144 张照片	34 734 221 条“喜欢”	Flickr 照片及“喜欢”记录
USA Patents	3 774 768 项专利	16 518 948 条引用关系	美国专利(1975~1999年)及引用关系
DBLP Data	4 215 613 篇论文	9 086 030 条与作者的关系	DBLP 论文及作者关系
musae-github	37 700 个深度开发者	289 003 条“关注”	GitHub 开发者关系网络
roadNet-CA	1 965 206 个路口	2 766 607 条道路	California 公路网络

2.3 复杂的网络分析需求

在社交网络、通信网络、计算机网络、道路网络等场景,也存在较大的数据挖掘分析的需求,包括节点分析、结构分析、路径查找、网络演化分析等。

以AMiner学术知识图谱为例,AMiner系统收集了7 900多万条论文信息、3 900多万条研究者信息,1.3亿论文引用关系、780万个知识实体以及3万多个学术会议/期刊的信息;AMiner同时提供了领域知识发展趋势可视化分析、人才专家排名与关系分析、引文溯源等功能^[35]。这些功能的实现建立在复

杂网络分析的基础上,如根据学者之间的合作关系进行学者社区发现、根据论文引用网络对学术成果进行分类、根据引文网络结构对论文进行重要性排序等。

利用网络生物学的方法对高通量基因表达数据进行分析 and 挖掘已经成为生物信息学重要的研究方向^[36]。目前人们已经对各种类型的分子生物网络进行了广泛的研究,如基因共表达网络(Gene Co-expression Network)、基因调控网络(Gene Regulatory Network)、蛋白质相互作用网络(Protein-protein

Interaction Network)、代谢网络(Metabolic Network)等。针对科研人员这一类网络需要提供高效的在线分析功能,如针对全球开放生物资源、文献、序列和疾病等万种数据源 100 亿级关联数据的知识发现,需在秒级时间内实现 6 步以上关联挖掘^[37]。

在金融领域,根据资金流动情况和账户、人员信息等信息进行金融风险预测,其相关技术在反洗钱、反欺诈应用中有较大需求^[38]。在流行病防控领域有根据人员社会关系,结合路径挖掘、节点重要度计算等技术追溯和预测疾病传播链,及早介入和切断传播路径的需求。在城市运营特别是轨道交通的规划与治理中,有大量站点和路径设计、人流量分析预测、轨道交通脆弱性分析等方面的需求^[39-40]。

从这些场景中,可以看出,“关系”作为一种重要类型的数据,广泛地存在于各种场景中,甚至比原始的“表记录”数据具备更大的规模,上层应用需要针对庞大的关系网络进行关系查询、计算和挖掘。然而,传统的关系模型采用分表的形式组织数据,缺少对关系的原生支持,当涉及表间数据的关系查询时,计算效率会大幅度下降,这种劣势在大规模数据下表现得尤为明显。

3 以图为中心的新型大数据技术栈

面对多元异构数据的融合管理、大规模关系网络的管理与复杂的网络分析需求,需要采取新的技术手段并构建新型的技术栈,这种技术栈应该具有如下特征。

(1)对信息世界的数据具有高度的表达能力,能很好地涵盖或映射到现有的 SQL 模型和 NoSQL 模

型,如关系模型、KV 模型、列式模型、文档模型、图模型。

(2)具备灵活的关系管理和关系计算分析的能力。

(3)要自成一体,软件栈自下而上保持简单自洽,而不是多种方法的混搭。

3.1 图数据模型的优势

图数据的基本类型是 $G=(V,E)$, V 是图 G 的顶点集合, E 是图 G 的边集合。图的边可以有方向,即当一张图是有向图时,对于任何的顶点 $u, v \in V, (u, v) \neq (v, u)$ 。

与关系模型相比,图数据模型具备如下优势。

(1)表达直观:图数据模型首先将世界里的数据表达成顶点和关系,其次再定义顶点和关系具有它们的属性。

(2)结构灵活:图的 schema 不需要预先定义,可以动态调整图的结构,以及增减顶点、边的属性。

(3)原生支持关系:图数据模式天然地适合处理事物之间的关系。

对于具有 M 个主键的 A 表和 N 个主键的 B 表,关系模型可借助中间关系表和 Join 操作来处理两表主键之间的关联关系,中间关系表的搜索空间是两表主键的笛卡尔积,即 $O(mn)$,对 B 表主键做了索引后,搜索空间可以优化为 $O(m \log(n))$;而在图数据模型里,主键(顶点)之间的关联关系被直接存储为边。实现这样的查询往往只需要 $O(m)$ 的搜索空间:通过一个顶点,获取到它的边,是一个 $O(1)$ 的操作。

图模型具有超强的表达能力,可以将关系模型、KV 模型、列式模型和文档模型通过一些映射方法,映射成图模型,映射如表 2 所示。

表 2 图数据模型对其他模型的表达能力

Table 2 Representation of Graph Model for Other Models

映射方法	顶点	边
关系模型	表的一行映射成一个顶点,每一列映射成顶点的属性	主外键关联映射成边
KV 模型	一个 KV 对映射成一个具有一个属性的顶点	无
列式模型	表的一行映射成一个顶点,每一列映射成顶点的属性	无
文档模型	一个文档映射成一个顶点,文档的字段映射成顶点的属性	文档的嵌套关系映射成边

3.2 图技术发展现状

近十几年来,图模型及其关键技术,包括图数据库、图计算、图分析挖掘、图可视化等,得到了充分发展。

近年来,数据库管理系统的发展趋势如图 4 所

示。可以看出,图数据库的发展势头迅猛。比较主流的图数据库系统有 Neo4j、OrientDB、JanusGraph、Cosmos DB、InfiniteGraph 等。为了应对大规模数据的管理,通常会采用分布式架构、副本等机制实现存

储和查询。例如, JanusGraph 采用“分布式查询引擎+分布式存储引擎”的组合架构, 其数据存储支持 Cassandra、HBase、BerkeleyDB, 索引存储支持 Elasticsearch、Solr、Lucene。

很多图数据库系统都具备实时数据的管理能

力, 如 TigerGraph 在单个项目上实现了千亿节点、万亿边的数据规模下, 支持每天 20 亿次的数据查询和更新; 与传统的静态图不同, 时序图的结构会随时间序列发生改变, 时序图相关的代表有 TGraph^[41]、DeltaGraph^[42]等。




图 4 图数据库发展趋势^[43]

Fig.4 Trend of Graph Database Development

分布式图处理系统可以按其基础模型分为两类, 一是基于整体同步并行模型(Bulk Synchronous Parallel, BSP)^[44]的专用图数据处理系统, 二是基于通用分布式系统(如 MapReduce 和 Spark)的图处理系统。前者如谷歌的 Pregel 分布式图处理框架^[45],

后者如 Spark 的 GraphX 系统。它们均采用图的分布式或并行处理方法, 即将图拆分成很多的子图, 然后分别对这些子图进行计算, 计算的时候可以分别迭代进行分阶段的计算, 即对图进行并行计算。近年来图计算框架的发展历史如图 5 所示。

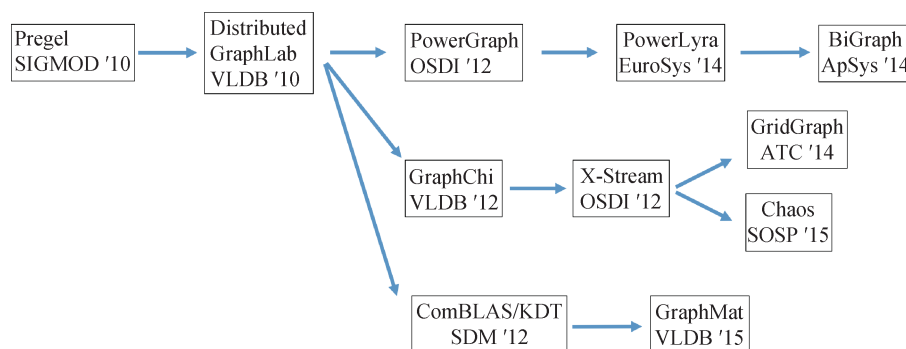


图 5 图计算框架发展历史^[46]

Fig.5 History of Graph Computing Framework

典型的图算法有 PageRank、Label Propagation、Random Walk 等。典型的图挖掘任务有社区网络分析(社区发现/图分割、连通子图发现)、图分类、图聚

类、频繁子图模式发现等。为了使用深度学习方法有效实现图挖掘, 往往需要借助于图嵌入(Graph Embedding)^[47]和图神经网络(Graph Neural

Network, GNN)^[48]技术。图嵌入技术包括DeepWalk、Text-Associated DeepWalk (TADW)、Discriminative Matrix Factorization (DMF)等;图神经网络包括图卷积神经网络(Graph Convolutional Network, GCN)^[49]和图注意力网络^[50]等。

图比其他可视化展示形式更适合探索数据的内部关系^[51],图的可视化分析包括图数据的基本统计、检索与映射、关系发现、结果展示等任务,典型的图可视化工具包括Gephi、Bloom、Pajek、WebVOWL^[52]、PGV (Paged Graph Visualization)^[53]等。在大规模图数据的场景下,通常采取层次化摘要、步进式交互探索等方式改善显示复杂等问题。RelFinder^[54]是基于RDF数据的交互式关系发现应用,通过SPARQL找到用户选择的元素在数据集中的映射对象,在得到数据集中的对象后,选定实体间的关系,将找到的关系展示给用户,用户可以控制搜索所得数据的可视化效果。

3.3 图技术应用现状

图模型及其技术在企业信息服务、互联网金融、生物医药、公共安全等领域都有着深入的应用。

在企业信息服务领域,图技术得到广泛的应用。例如,“天眼查”基于政府公开数据,包括工商数据、法律诉讼、新闻动态、企业年报等全量信息,在线提供全国包含2亿家社会实体、90余种数据维度的信息,涵盖企业名称、机构类型、地域、经营状况、知识产权等信息,并提供了查人、查关系、查风险、查“老赖”、天眼地图、高级搜索等功能。

金融行业拥有大量的专业数据,如公司、组织机构、个人的存贷款情况,以及征信和投资数据、交易记录、消费概况,可以通过图数据模型将所有实体的属性及关系全面呈现出来。蚂蚁金服研发的实时金融级分布式图数据库GeaBase^[55]已广泛应用于其生态体系中。当用户的金融操作出现异常状况时,可以通过个人特征的监控,操作的不一致性检测,异常状况的分析,发现隐藏其中的潜在风险,进行风险控制及反欺诈检测^[56]。

在生物医药领域,Chem2Bio2RDF Dashboard系统集成了化学、生物、药物领域的关联数据,用来发现两个实体或概念之间的路径^[57];BioNav系统能够基于本体技术有效发现药物和疾病之间的潜在的

关系^[58]。

Krebs将图技术应用到犯罪分析,介绍了如何使用互联网上新闻源提供的公开数据来绘制隐蔽网络,并针对2001年9月11日的恐怖袭击事件进行研究^[59]。通过公开数据,以19个死亡的劫机者为中心,根据嫌疑人的联系人名单绘制形成美国9·11事件的恐怖分子网络,如图6所示。通过社会网络分析方法发掘网络图中更深层次的内在联系,相关的数据分析可以揭示出这个网络最核心的联系人、与其他成员联系最广泛的人、为两个彼此并不直接联系的成员提供联系纽带的人等,从而快速找出恐怖活动的幕后策划者。

此外,图技术还应用到城市人口流动分析^[60]、政治意识形态检测^[61]、公共健康^[62-63]等方面。

3.4 以图为中心的新型大数据技术栈

综上,图数据模型具备表达直观、结构灵活、关系管理高效等多种优势,图技术的发展日趋成熟完善,图技术的应用场景也越来越丰富。基于此,本文提出以图(而不是以SQL)为中心构建新型大数据技术栈的思路。该技术栈具备如下特征。

(1)满足软件栈的层次关系:即上层调用下层的

服务。

(2)面向大数据场景:区别于传统的单机、关系型数据管理场景,充分考虑到大数据时代的数据湖、数据中台等需求,同时有效兼容Hadoop/Spark生态。

(3)以图为中心(Graph Centric):提倡采用“一张图”而不是“一堆表”来构建数据基础设施,同时提供系列基于图的数据管理、处理、分析方法。

完整的技术栈包括模型、语言、关键技术、工具、场景、应用等几个层次,设计如图7所示。

与传统的SQL技术栈相比,新型技术栈的特色组件包括:基于图模型的数据湖、图数据仓库、gETL、图数据中台。

(1) 基于图模型的数据湖

数据湖概念的提出,旨在为企业提供一个完整的存储库,用以存储原始的或初加工的数据,包括结构化数据(数据库表等)、半结构化数据(CSV、log、XML、JSON)和非结构化数据(邮件、文档、二进制图像、音频、视频等)^[64]。

由于数据湖的多源异构特征,目前针对数据湖

图6 恐怖分子网络^[59]

Fig.6 Network for Terrorists' Relationship

的管理往往采用一些混搭的架构完成,如采用分布式文件系统实现非结构化文档的存储、采用HDFS存储结构化和半结构化的数据。华为云基于“云存储+CarbonData”构建的新一代数据湖,实现了实时数据接入、DB数据同步、高性能查询和分析等能力,使云化数据湖可以真正成为企业数据架构的基础。AWS于2019年推出数据湖管理工具AWS Lake Formation,对数据进行摄取、清理、分类、转换以及保护的工作,方便后续分析或是机器学习使用。Databricks则将数据湖和数据仓库结合起来,形成

LakeHouse方案,并推出Delta Lake^[65]。Delta Lake采用Bronze表、Silver表和Gold表三类表分别存储摄取数据、转换数据以及特征工程数据,并维护它们之间的流转,如图8所示。

本技术栈提出基于“一张图”而不是“一堆表”构建数据湖的思路,与传统方法相比,图数据模型可以管理跨域数据、结构化与非结构化数据之间的关系,同时还可以管理分级数据之间的血缘关系。

(2) 图数据仓库

与数据湖的用途不一样,数据仓库主要处理历

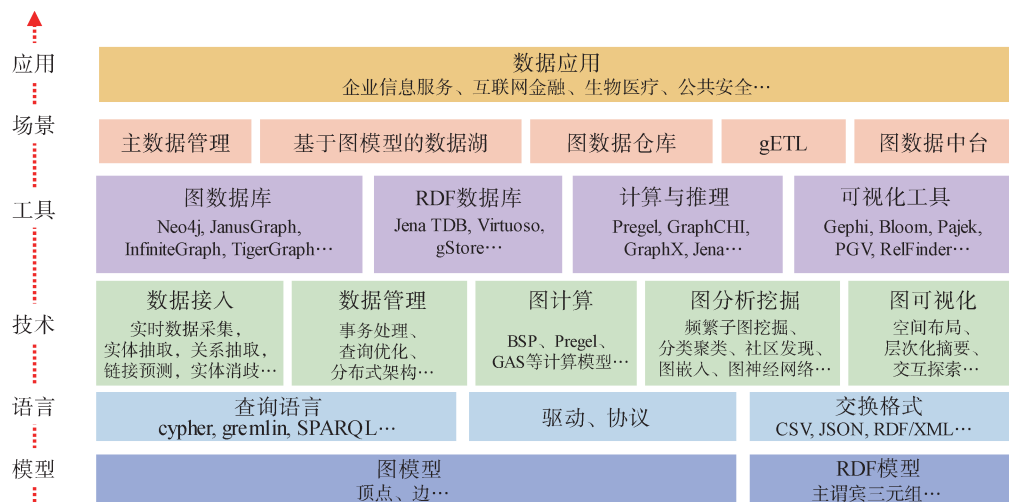


图7 以图为中心的新型大数据技术栈

Fig.7 Graph Centric Big Data Technology Stack

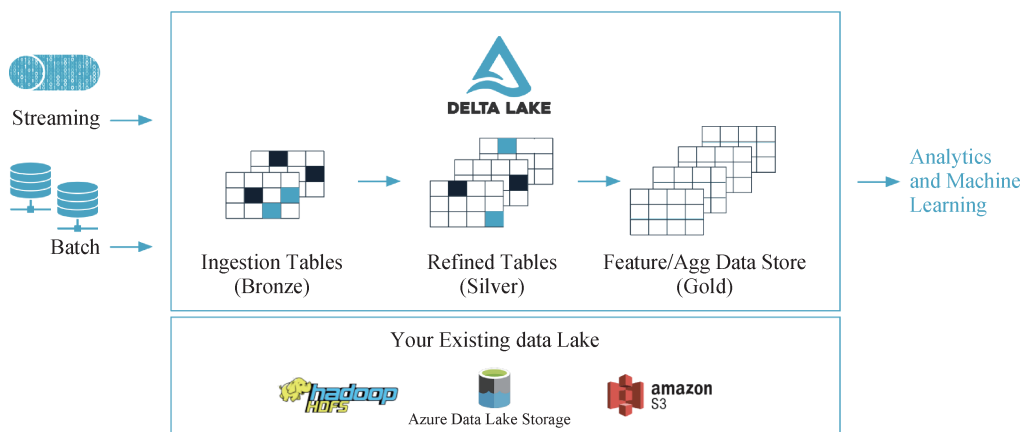
图8 数据湖管理系统Delta Lake^[65]

Fig.8 Data Lake Management System Delta Lake

史的、结构化的数据。传统的数据仓库很难实现跨数据集或数据域的处理,同时提供的分析服务以多维统计分析为主,包括钻取(Roll-up和Drill-down)、切片(Slice)、切块(Dice)以及旋转(Pivot)等多维操作。

本技术栈提出图数据仓库的概念,提倡基于图模型和图技术构建数据仓库。与传统的数据仓库相比,在多维统计分析服务之外,图数据仓库更适合对图的要素进行统计,如实体统计、关系统计、社区发现、聚类等。图数据的统计同样具有不同的粒度,可以定义上卷(Roll-up)和下钻(Drill-down)等操作^[66]。

ETL在数据仓库的构建过程中扮演着重要的角

色,为了与传统的SQL ETL区分开,本技术栈提出gETL。gETL指针对图数据的抽取、转换和载入工作,包括从原始的结构化、非结构化文本中进行实体抽取、关系抽取和预测、实体消歧等。以抽取任务为例,gETL可以将CSV、JSON、XML、SQL等格式的多源数据,转换成“顶点-边”的图数据。

(3) 图数据中台

数据中台的概念最早由阿里巴巴提出,旨在通过企业内外部多源异构的数据采集、治理、建模、分析和应用,实现One Data(汇聚企业各种数据)、One ID(数据遵循相同的标准和统一标识)、One Service(提供统一的数据服务)的目标^[67]。

在数据中台中,基于图模型及图技术可以更好地实现 One Linked Data(汇聚并关联企业各种数据)、One Traceable ID(数据遵循相同标准和统一可追溯的标识)和 One Graph Service(提供统一的图服务)。图可以表达数据之间的关联以及 ETL 过程中的数据血缘,从而实现数据资产中内容的关联化以

及 ID 的可溯源。如图 9 所示,可以针对应用的需求定制“图谱服务”,如针对某类实体的画像、针对某两类实体的合作网络、跨实体间的路径发现等。图计算后台完成这些复杂任务的调度与执行,前端的图数据应用通过服务接口的调用,即可展示出相应的界面。

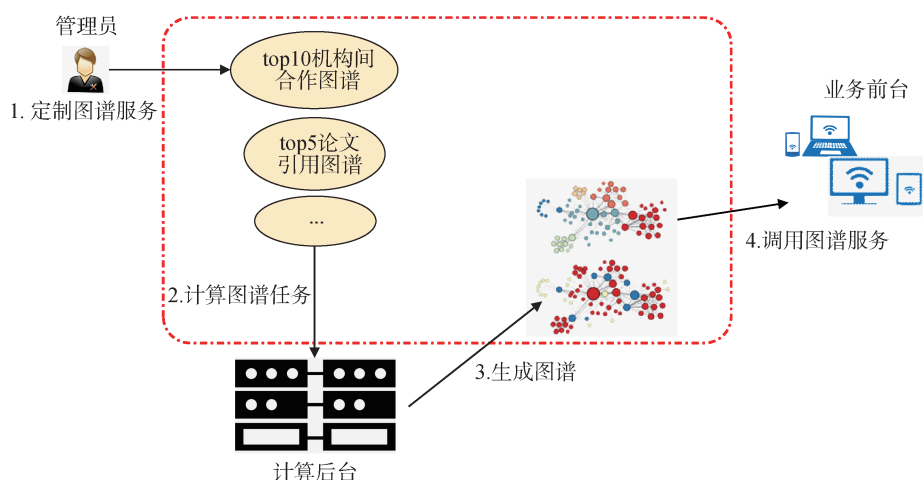


图 9 图数据中台

Fig.9 Graph Data Middle Platform

考虑到图在语义网、开放数据、知识图谱等知识应用方面具有较大的价值。在模型层引入资源描述框架(RDF)模型,在工具层引入 RDF 数据库,数据中台可以基于 RDF Graph 构建富含语义的知识图谱。

综上所述,与以 SQL 为中心的技术栈进行对比,以图为中心的技术栈在数据库、数据湖、数据仓库、ETL、大数据中台的构建方面具备一些特色和优势,如表 3 所示。

表 3 以 SQL、图为中心的技术栈之间的比较

Table 3 Comparison of SQL Centric and Graph Centric Technology Stack

工具技术	以 SQL 为中心的技术栈	以图为中心的技术栈
数据库	关系数据库 查询语言为 SQL 驱动包括 ODBC、JDBC、DAO 等	图数据库 查询语言包括 Cypher、SPARQL、Gremlin 等
数据湖	结构化、半结构化、非结构化数据的集中混搭式管理 其中结构化数据以关系表为主	一张图管理:基于图的结构化、半结构化、非结构化数据的融合管理
数据仓库	多维数据仓库	多维数据仓库+图数据仓库,增强关系挖掘、社区挖掘等能力
ETL	ETL 多基于 SQL 进行	gETL:以图数据为主,包括实体抽取、关系抽取、实体消歧、链接预测等任务
大数据中台	数据服务以 SQL 报表、数据库 CRUD 为主	图数据:提倡以图为核心实现数据资产的管理,服务以网络分析、图谱可视化为主中台

4 智能融合数据管理系统 PandaDB

传统的数据湖采用多种管理系统的混搭完成结构化、半结构化、非结构化数据的存储,在这种方案

中,结构化、半结构化数据采用 SQL、NoSQL 数据库进行存储,非结构化数据存储在本地文件系统或分布式文件系统(HDFS、CEPH、MooseFS 等)中。这种存储方式存在一个明显的不足:非结构化数据的数

据游离于数据库之外,针对非结构化数据的内容理解严重依赖于上层应用程序;同时,非结构化数据与结构化数据之间存在的天然的关联未能得到很好的揭示,如人物照片与人物信息之间的关联、论文 PDF 与论文元数据之间的关联、视频与应用案例之间的关联等。

本文提出智能融合数据管理系统 PandaDB,旨在实现大规模结构化、非结构化数据的统一存储和查询,同时通过集成人工智能的计算能力,实现对非结构化数据内在信息的透明化访问。

4.1 非结构化数据的表达

PandaDB 基于属性图模型实现结构化、非结构化数据的融合管理。如图 10 所示,在属性图中,非结构化数据表达成一个 Package 类型的数据属性,Package 与 String、Integer、Date 等属性类型一起,构成 PandaDB 的类型系统。

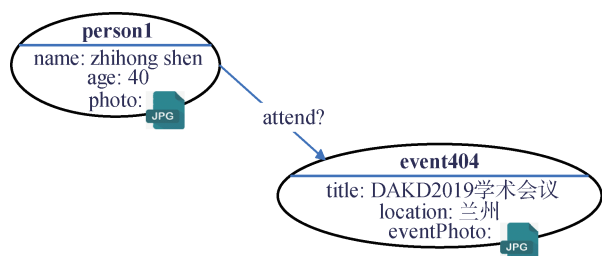


图 10 采用属性图表示结构化、非结构化数据
Fig.10 Structured and Unstructured Data in Property Graph Model

Package 的原始数据表达为一个二进制大对象 (Binary Large Object, BLOB),通过打开一个二进制流实现 BLOB 的读写。此外,为了增强 PandaDB 对 Package 的理解能力,Package 属性可以通过两种方式动态扩展为次级属性。

(1) 次级属性集方法

将 Package 扩展为多个二级属性的集合。例如,将一个名为 photo 的 Package 属性扩展为: {type: "car", plateNumber: "京 X12345", color: "red"}, 其中, type、plateNumber、color 即为二级属性。

(2) 次级属性图方法

将 Package 扩展为一个场景描述的属性图。例如,将一个名为 photo 的 Package 属性扩展为如下的属性图: [:person|type:"boy"]-(SIT_ON)-[:horse

{color:"white"}]

该属性图用以描述“一个男孩骑着一匹白马”的场景,其中包含两个表示实体的顶点、一个表示位置关系的边。

4.2 统一查询语言

PandaDB 针对标准化的 Cypher 语法进行扩展,称为 CypherPlus,该扩展支持 Package 的数据表示、属性抽取以及语义计算。

(1) 数据表示:在 Cypher 语言中采用 <schema://path> 的方式表达 Package 数据源, schema 可以为 FILE、HTTP(S)、FTP(S)、BLOB 等多种类型。

(2) 属性抽取:定义了 var->propertyKey 的操作符,如针对 photo 属性执行 photo->plateNumber,即可抽取到 photo 中的车牌号。

(3) 语义计算:针对 Package 属性的计算,如计算两张图片之间是否相似、是否包含等。目前 CypherPlus 支持的语义操作符如表 4 所示。

表 4 CypherPlus 针对 Package 定义的语义操作符
Table 4 Semantic Operation Symbols in CypherPlus for Package

操作符	含义	示例
::	计算 x 和 y 之间的相似度	x::y=0.7
~:	计算 x 和 y 是否相似?	x~:y=true
!:	计算 x 和 y 是否不相似?	x!:y=false
<:	计算 x 是否在 y 里	x<:y=true
>:	计算 x 是否包含 y	y>:x=true

针对图 10 所示的图数据,执行如下查询:

match (p: Person), (e: Event) where p.photo<: e.eventPhoto create (p)-[:attend]->(e)

如果人物 person1 在 event404 事件的照片中出现,则会在它们之间构建一条 attend 边。以上语句中, -> 和 <: 即为 CypherPlus 的属性抽取操作符和语义计算操作符。

4.3 基于 AI 的非结构化数据信息抽取

针对非结构化数据的信息抽取任务(包括次级属性集、次级属性图的抽取),PandaDB 定义了 AIPM 模块。AIPM 模块采用“框架+插件”的架构,提供基于 CPU/GPU 等异构计算资源、针对大规模非结构化数据进行的多元化 AI 计算服务,包括文本相似度计算、语音识别、动物分类、头像识别等。如需新的服务,按照 AIPM 的规范封装集成一个新的插件即可。

图 11 为 AIPM 技术架构,为屏蔽非结构化数据信息抽取方法的复杂依赖问题,AIPM 通过容器技术

屏蔽了不同算法之间的依赖冲突,并实现了 AI 算子的快速部署。

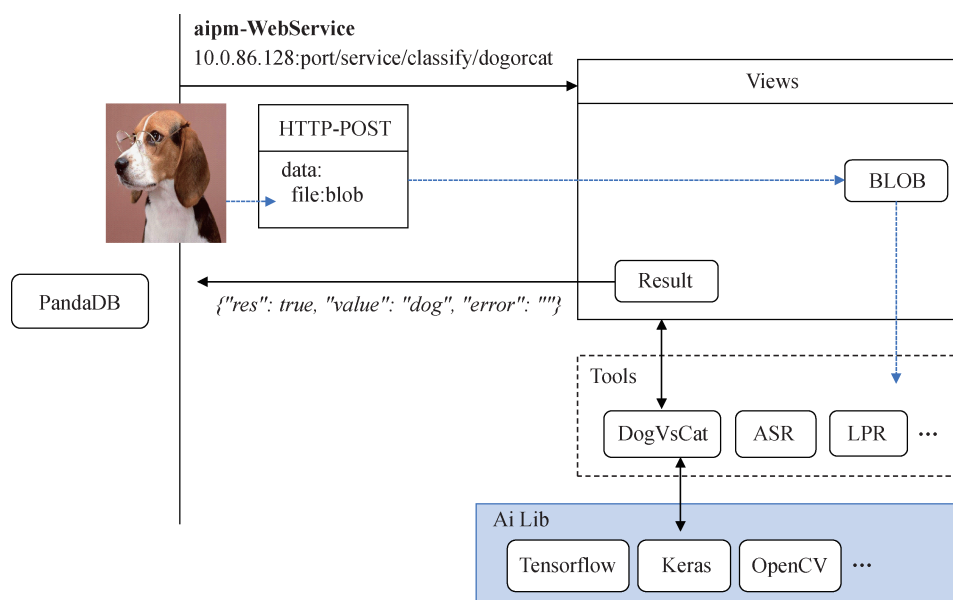


图 11 AIPM 技术架构

Fig.11 Architecture of AIPM

4.4 查询引擎与加速机制

PandaDB 基于 openCypher 开源项目,实现对主流的 Cypher 查询语言的支持。Cypher 是 Neo4j 提出的一种适用于开发人员、数据科学家和运营专业人员的声明式语言。同时,Cypher 也致力于 ISO 标准图形查询语言(Graph Query Language,GQL)的制定。openCypher 项目提供了 Cypher 开发的相关资源,包括 Cypher 语言规范、样式指南、兼容性工具等。

如图 12 所示,与 SQL 查询引擎机理类似,

Cypher 查询语言的执行也经过解析、语义检查、逻辑计划、物理计划等阶段。PandaDB 结合逻辑计划、存储引擎、索引结构生成物理计划,从而实现了 Cypher 查询能力。

属性是属性图的主要要素,为了提供大规模属性存储的能力,同时加速对属性的检索性能,PandaDB 设计了属性外置(External Property Store)的机制,即将大规模的属性存储在外部的一个支持全文索引的文档数据库中,同时采取谓词下推和列剪裁的方法,优先执行属性过滤。

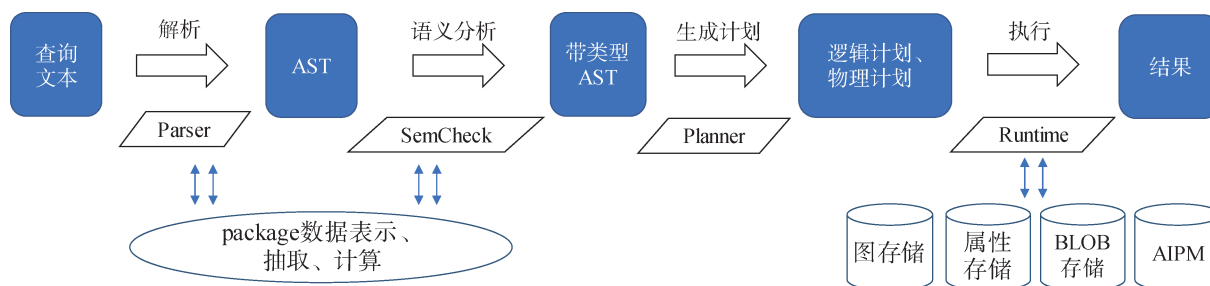


图 12 Cypher 查询的执行过程

Fig.12 Process of Cypher Query Execution

4.5 分布式架构设计与实现

PandaDB 针对非结构化数据、属性数据、图结构数据采取分布式存储结构,同时依赖分布式 Cypher 执行引擎完成查询任务。集群采用 Apache Zookeeper 作为协调器,从而避免了单点故障和压力过载。系统总体架构如图 13 所示。

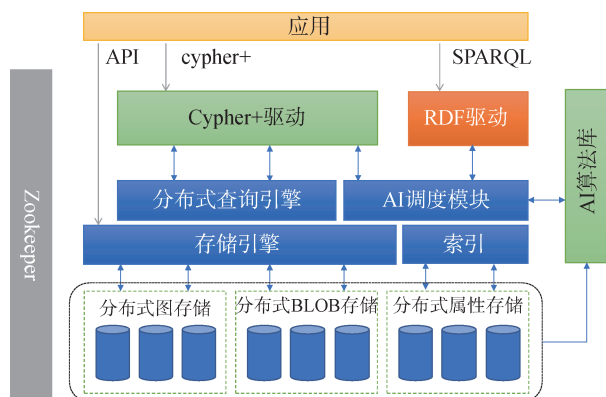


图 13 PandaDB 总体架构

Fig.13 Architecture of PandaDB

在 PandaDB v0.1 版本中,图存储基于 Neo4j 社区版实现,BLOB 的存储基于 Apache HBase 实现,属性存储基于 Apache Solr 实现;在 PandaDB v0.2 版本中,为进一步提高系统的整体性能,降低运维成本,则采取自主的存储引擎,包括分布式非结构化数据存储 RegionFS、分布式属性存储 Bamboo 等。

5 结 语

自 20 世纪 70 年代起,关系模型及 SQL 语言统治数据管理与分析的世界已长达 50 年之久,从数据库到数据仓库,即便在大数据时代,它们仍然以 SQL on Hadoop、SQL over NoSQL、Analytical SQL 等多种形态展示出强大的生命力。本文在新的技术挑战和应用场景下,结合关系模型存在的不足和图数据模型的突出优势,提出基于图模型的数据湖、图数据仓库、gETL、图数据中台等思路,并继而提出以图为中心的新型大数据技术栈。

该技术栈在世界微生物数据中心知识服务平台^[68]、国家自然科学基金大数据知识管理服务平台^[69]、烟草科研数据融合与关联挖掘关键技术研究(简称 TobaccoRDP)等项目中得到部分或完整的实

践。TobaccoRDP 通过图技术栈的应用,汇聚了来自烟草科研知识图谱、烟草育种大数据平台、烟叶质量大数据分析服务平台的多元异构数据,构建了统一的烟草科研数据湖,并形成图数据中台,提供了面向应用的主题库、多维统计、地理信息统计、学术知识图谱等形式的服务。TobaccoRDP 采用 PandaDB 作为核心组件,实现了对数据湖和数据仓库的构建与管理,在数据资源存储与检索中性能良好,同时对图分析和挖掘提供了良好的支撑。

与传统的 SQL 技术栈相比,以图为中心的大数据技术栈具备模型表达能力强、关系网络分析挖掘能力强等优势,可以有效地实现多元异构数据的融合管理、大规模关系网络的管理与复杂的网络分析。然而,作为一种新型的全套方案,以图为中心的技术栈无论是在图数据仓库、gETL、图数据中台等技术的成熟度方面,还是在完整的应用生态方面,与 SQL 技术栈还存在较大的差距。但随着技术与应用的不断深入,这些不足会逐渐得以克服,以图为中心的新型大数据技术栈终将在企业信息服务、互联网金融、生物医疗、公共安全等应用场景发挥更大的价值。

参考文献:

- [1] Codd E F. Derivability, Redundancy and Consistency of Relations Stored in Large Data Banks[J]. ACM SIGMOD Record, 2009, 38(1): 17-36.
- [2] Codd E F, Codd S B, Salley C T. Providing OLAP (On-Line Analytical Processing) to User-analysts. An IT Mandate[R]. White Paper. Arbor Software Corporation, 1993.
- [3] The Kettle Open Source Data Integration Project[EB/OL]. [2020-04-02]. <http://www.kettle.be/>.
- [4] Talend - A Cloud Data Integration Leader (modern ETL) [EB/OL]. [2020-04-02]. <https://www.talend.com/>.
- [5] Enterprise Cloud Data Management | Informatica [EB/OL]. [2020-04-02]. <https://www.informatica.com/>.
- [6] DataX[EB/OL]. [2020-04-02]. <https://github.com/alibaba/DataX>.
- [7] Oracle GoldenGate [EB/OL]. [2020-04-02]. <https://www.oracle.com/middleware/technologies/goldengate.html>.
- [8] Thusoo A, Sarma J S, Jain N, et al. Hive: A Warehousing Solution over a Map-reduce Framework[J]. Proceedings of the VLDB Endowment, 2009, 2(2): 1626-1629.
- [9] Kornacker M, Behm A, Bittorf V, et al. Impala: A Modern, Open-Source SQL Engine for Hadoop[C]//Proceedings of the 7th Biennial Conference on Innovative Data Systems Research

- (CIDR'15). 2015.
- [10] Akhtar S, Magham R. Pro Apache Phoenix: An SQL Driver for HBase[M]. Apress, 2016.
 - [11] SQL Interface for Solr Cloud[EB/OL]. [2020-04-02]. <https://github.com/bluejoe2008/solr-sql>.
 - [12] Begoli E, Camacho-Rodríguez J, Hyde J, et al. Apache Calcite: A Foundational Framework for Optimized Query Processing over Heterogeneous Data Sources[C]//Proceedings of the 2018 International Conference on Management of Data. 2018: 221-230.
 - [13] Arasu A, Babu S, Widom J. The CQL Continuous Query Language: Semantic Foundations and Query Execution[J]. The VLDB Journal, 2006, 15(2): 121-142.
 - [14] Cai L, Chen J J, Chen J, et al. Fusion Insight LibrA: Huawei's Enterprise Cloud Data Analytics Platform[J]. Proceedings of the VLDB Endowment, 2018, 11(12): 1822-1834.
 - [15] Apache Kylin | Analytical Data Warehouse for Big Data [EB/OL]. [2020-04-02]. <http://kylin.apache.org/cn/>.
 - [16] Fernandes S, Bernardino J. What is BigQuery? [C]//Proceedings of the 19th International Database Engineering & Applications Symposium. 2015: 202-203.
 - [17] BigQuery ML[EB/OL]. [2020-04-02]. <https://cloud.google.com/bigquery-ml/docs/bigqueryml-intro>.
 - [18] Wang Y, Yang Y, Zhu W G, et al. SQLFlow: A Bridge Between SQL and Machine Learning[OL]. arXiv Preprint, arXiv: 2001.06846.
 - [19] Katal A, Wazid M, Goudar R H. Big Data: Issues, Challenges, Tools and Good Practices[C]//Proceedings of the 6th International Conference on Contemporary Computing (IC3). IEEE, 2013: 404-409.
 - [20] Gaag A, Kohn A, Lindemann U. Function-based Solution Retrieval and Semantic Search in Mechanical Engineering[C]//Proceedings the 17th International Conference on Engineering Design (ICED 09). 2009: 147-158.
 - [21] Cattell R. Scalable SQL and NoSQL Data Stores[J]. ACM SIGMOD Record, 2010, 39(4):12-27.
 - [22] Wang G X, Tang J F. The NoSQL Principles and Basic Application of Cassandra Model[C]//Proceedings of International Conference on Computer Science & Service System (CSSS). 2012: 1332-1335.
 - [23] Eric B. CAP Twelve Years Later: How the "Rules" Have Changed [J]. Computer, 2012, 45(2): 23-29.
 - [24] Lu J H, Holubová I. Multi-model Data Management: What's New and What's Next? [C]//Proceedings of the 20th International Conference on Extending Database Technology(EDBT). 2017: 602-605.
 - [25] Kiran M, Murphy P, Monga I, et al. Lambda Architecture for Cost-effective Batch and Speed Big Data Processing[C]//Proceedings of 2015 IEEE International Conference on Big Data. IEEE, 2015: 2785-2792.
 - [26] Questioning the Lambda Architecture [EB/OL]. [2020-04-02]. <http://radar.oreilly.com/2014/07/questioning-the-lambdaarchitecture.html>.
 - [27] Duggan J, Elmore A J, Stonebraker M, et al. The BigDAWG Polystore System[J]. ACM SIGMOD Record, 2015, 44(2): 11-16.
 - [28] Kwak H, Lee C H, Park H S, et al. What is Twitter, a Social Network or a News Media? [C]//Proceedings of the 19th International Conference on World Wide Web. 2010: 591-600.
 - [29] Backstrom L, Boldi P, Rosa M, et al. Four Degrees of Separation [C]//Proceedings of the 4th Annual ACM Web Science Conference. 2012: 45-54.
 - [30] 漆桂林,高桓,吴天星.知识图谱研究进展[J].情报工程,2017,3(1): 4-25. (Qi Guilin, Gao Huan, Wu Tianxing. The Research Advances of Knowledge Graph[J]. Technology Intelligence Engineering, 2017,3(1):4-25.)
 - [31] SN SciGraph-A Linked Open Data Platform for the Scholarly Domain[EB/OL]. [2020-04-02]. <https://www.springernature.com/gp/researchers/scigraph>.
 - [32] Zhang F J, Liu X, Tang J, et al. OAG: Toward Linking Large-scale Heterogeneous Entity Graphs[C]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2019: 2585-2595.
 - [33] Stanford Large Network Dataset Collection [EB/OL]. [2020-04-02].<https://snap.stanford.edu/data/>.
 - [34] BigDND: Big Dynamic Network Data [EB/OL]. [2020-04-02]. <http://projects.csail.mit.edu/dnd/>.
 - [35] Tang J. AMiner: Toward Understanding Big Scholar Data[C]//Proceedings of the 9th ACM International Conference on Web Search and Data Mining. 2016: 467.
 - [36] 汪涛,蒋庆华,彭佳杰,等.基因共表达网络的构建及分析方法研究综述[J].智能计算机与应用,2014,4(6):47-50,53.(Wang Tao, Jiang Qinghua, Peng Jiajie, et al. A Review of the Construction and Analysis of Gene Co-expression Network[J]. Intelligent Computer and Applications, 2014, 4(6): 47-50, 53.)
 - [37] 黎建辉,沈志宏,孟小峰.科学大数据管理:概念、技术与系统[J].计算机研究与发展,2017,54(2):235-247.(Li Jianhui, Shen Zhihong, Meng Xiaofeng. Scientific Big Data Management: Concepts, Technologies and System[J]. Journal of Computer Research and Development, 2017, 54(2): 235-247.)
 - [38] Liu Z Q, Chen C C, Yang X X, et al. Heterogeneous Graph Neural Networks for Malicious Account Detection[C]//Proceedings of the 27th ACM International Conference on Information and Knowledge Management. 2018: 2077-2085.
 - [39] Jin J G, Tang L C, Sun L, et al. Enhancing Metro Network Resilience via Localized Integration with Bus Services[J]. Transportation Research Part E: Logistics and Transportation Review, 2014, 63: 17-30.

- [40] Seriani S, Fernandez R. Planning Guidelines for Metro-bus Interchanges by Means of a Pedestrian Microsimulation Model [J]. Transportation Planning & Technology, 2015, 38(5): 569-583.
- [41] Huang H X, Song J H, Lin X L, et al. TGraph: A Temporal Graph Data Management System[C]//Proceedings of the 25th ACM International Conference on Information and Knowledge Management. 2016: 2469-2472.
- [42] Khurana U, Deshpande A. Efficient Snapshot Retrieval over Historical Graph Data [C]//Proceedings of the 2013 IEEE International Conference on Data Engineering (ICDE2013). 2013: 997-1008.
- [43] DBMS Popularity Broken down by Database Model[EB/OL]. [2020-04-02]. https://db-engines.com/en/ranking_categories.
- [44] Valiant L G. A Bridging Model for Parallel Computation[J]. Communications of the ACM, 1990, 33(8): 103-111.
- [45] Malewicz G, Austern M H, Bik A J, et al. Pregel: A System for Large-scale Graph Processing[C]//Proceedings of the 2010 ACM SIGMOD International Conference on Management of Data. 2010: 135-146.
- [46] 图计算框架回顾 [EB/OL]. [2020-04-02]. <https://blog.csdn.net/wjwangluo/article/details/66972393>. (Review of Graph Calculation Framework [EB/OL]. [2020-04-02]. <https://blog.csdn.net/wjwangluo/article/details/66972393>.)
- [47] Yan S C, Xu D, Zhang B Y, et al. Graph Embedding and Extensions: A General Framework for Dimensionality Reduction [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2006, 29(1): 40-51.
- [48] Scarselli F, Gori M, Tsoi A C, et al. The Graph Neural Network Model[J]. IEEE Transactions on Neural Networks, 2008, 20(1): 61-80.
- [49] Defferrard M, Bresson X, Vandergheynst P. Convolutional Neural Networks on Graphs with Fast Localized Spectral Filtering[C]//Proceedings of the Advances in Neural Information Processing Systems (NIPS). 2016:3844-3852.
- [50] Veličković P, Cucurull G, Casanova A, et al. Graph Attention Networks[C]//Proceedings of the International Conference on Learning Representations (ICLR). 2018.
- [51] Palmer S, Rock I. Rethinking Perceptual Organization: The Role of Uniform Connectedness[J]. Psychonomic Bulletin & Review, 1994, 1(1): 29-55.
- [52] Lohmann S, Link V, Marbach E, et al. WebVOWL: Web-based Visualization of Ontologies [C]//Proceedings of the 2014 International Conference on Knowledge Engineering and Knowledge Management. 2014: 154-158.
- [53] Deligiannidis L, Kochut K J, Sheth A P. RDF Data Exploration and Visualization[C]//Proceedings of the ACM 1st Workshop on CyberInfrastructure: Information Management in eScience. 2007: 39-46.
- [54] Heim P, Hellmann S, Lehmann J, et al. RelFinder: Revealing Relationships in RDF Knowledge Bases[C]// Proceedings of the 4th International Conference on Semantic and Digital Media Technologies. 2009: 182-187.
- [55] Hu X, Ye X M, Yu B Q, et al. GeaBase: A High-performance Distributed Graph Database for Industry-scale Applications[J]. International Journal of High Performance Computing and Networking, 2019, 15(1/2): 12-21.
- [56] 田莉霞. 知识图谱研究综述[J]. 软件, 2020, 41(4): 67-71. (Tian Lixia. Review on Knowledge Graphs[J]. Computer Engineering & Software, 2020, 41(4): 67-71.)
- [57] Dong X, Ding Y, Wang H J, et al. Chem2Bio2RDF Dashboard: Ranking Semantic Associations in Systems Chemical Biology Space[C]// Proceedings of FWCS2010. 2010.
- [58] Vidal M E, Raschid L, Márquez N, et al. BioNav: An Ontology-based Framework to Discover Semantic Links in the Cloud of Linked Data[C]//Proceedings of the 7th International Conference on the Semantic Web: Research and Applications. 2010: 441-445.
- [59] Krebs V. Uncloaking Terrorist Networks[J]. First Monday, 2002, 7(4). <https://doi.org/10.5210/fm.v7i4.941>.
- [60] Zhuang C Y, Yuan N J, Song R H, et al. Understanding People Lifestyles: Construction of Urban Movement Knowledge Graph from GPS Trajectory[C]//Proceedings of the 26th International Joint Conference on Artificial Intelligence. AAAI Press, 2017: 3616-3623.
- [61] Chen W, Zhang X, Wang T J, et al. Opinion-aware Knowledge Graph for Political Ideology Detection[C]//Proceedings of the 26th International Joint Conference on Artificial Intelligence. AAAI Press, 2017: 3647-3653.
- [62] Christakis N A, Fowler J H. The Spread of Obesity in a Large Social Network over 32 Years[J]. New England Journal of Medicine, 2007, 357(4): 370-379.
- [63] Fowler J H, Christakis N A. Dynamic Spread of Happiness in a Large Social Network: Longitudinal Analysis over 20 Years in the Framingham Heart Study[J]. British Medical Journal, 2008, 337: 1-9.
- [64] Khine P P, Wang Z S. Data Lake: A New Ideology in Big Data Era[C]//Proceedings of the 4th Annual International Conference on Wireless Communication and Sensor Network. 2018, 17: 03025.
- [65] Reliable Data Lakes at Scale [EB/OL]. [2020-04-02]. <https://delta.io/>.
- [66] Chen C, Yan X F, Zhu F D, et al. Graph OLAP: Towards Online Analytical Processing on Graphs[C]//Proceedings of the 8th IEEE International Conference on Data Mining. 2008:103-112.
- [67] 车品觉. 建设数据中台, 赋能改革创新[J]. 新经济导刊, 2018(10): 22-24. (Che Pinjue. Building Data Middle Platform, Enable Creative Innovation[J]. New Economy Weekly, 2018(10): 22-24.)

- [68] Wu L H, Sun Q L, Desmeth P, et al. World Data Centre for Microorganisms: An Information Infrastructure to Explore and Utilize Preserved Microbial Strains Worldwide[J]. *Nucleic Acids Research*, 2017, 45(D1): D611-D618.
- [69] 沈志宏,姚畅,侯艳飞,等. 关联大数据管理技术:挑战、对策与实践[J]. *数据分析与知识发现*,2018,2(1):9-20.(Shen Zhihong, Yao Chang, Hou Yanfei, et al. Big Linked Data Management: Challenges, Solutions and Practices[J]. *Data Analysis and Knowledge Discovery*, 2018, 2(1): 9-20.)

作者贡献声明:

沈志宏:提出研究思路,设计研究方案,负责主要内容的撰写;

赵子豪:负责 2.3、3.3、4.3 节等内容的撰写,负责格式修订和图片编辑;

王海波:负责 3.3、3.4 节;TobaccoRDP 应用等内容的撰写,并对技术栈的架构做出补充。

利益冲突声明:

所有作者声明不存在利益冲突关系。

收稿日期:2020-05-20

收修改稿日期:2020-06-09

Big Data Technology Stack Shifting: From SQL Centric to Graph Centric

Shen Zhihong¹ Zhao Zihao^{1,2} Wang Haibo¹

¹(Computer Network Information Center, Chinese Academy of Sciences, Beijing 100190, China)

²(University of Chinese Academy of Sciences, Beijing 100049, China)

Abstract: [Objective] The traditional SQL centric technology stack cannot handle multivariant and heterogeneous data management, large-scale network management, as well as complex network analysis. Therefore, we proposed a new graph centric technology stack for big data. [Methods] First, we analyzed the advantages of graph-based data model and established a new graph centric technology stack. Then, we developed PandaDB, an intelligent fusion data management system. [Results] The new technology stack performed well in the applications of biological data network and scholar knowledge graph. PandaDB could manage structured and unstructured data fusion. [Limitations] It is difficult to further promote this technology stack due to the lack of supporting tools and complete application ecology. [Conclusions] Our new technology stack will play a greater role in big data applications.

Keywords: Graph Model Graph Database Data Warehouse Technolgy Stack